

AgroSearch - Motor de Busca Inteligente

Disciplina: Tendências em Ciência da Computação.

1. Objetivo

O AgroSearch foi desenvolvido como um protótipo de motor de busca textual para recuperação de informações em documentos sobre agricultura. A aplicação permite processar uma coleção de documentos, construir um índice invertido e realizar consultas ranqueadas por relevância. A solução foi implementada em Python com interface Streamlit, mantendo o índice invertido e o cálculo de TF-IDF implementados manualmente, sem o uso de bibliotecas de alto nível para essas operações.

2. Implementação

A base utilizada contém cinco documentos sobre soja, irrigação, controle de pragas, adubação e cultivo orgânico. O processamento foi organizado em três fases integradas.

Fase 1 - Pré-processamento. O texto é tokenizado e normalizado para letras minúsculas e sem acentos. A aplicação também permite ativar ou desativar, por meio de checkboxes, a remoção de stopwords e o stemming. Após o processamento, os tokens de cada documento e o vocabulário resultante são exibidos dinamicamente na interface.

Fase 2 - Índice Invertido. A partir dos tokens processados é criada a estrutura Documento -> Termos e, em seguida, o índice invertido Termo -> Documentos. Dessa forma, cada termo do vocabulário é associado aos documentos em que ocorre. Os dois índices são apresentados lado a lado no Streamlit.

Fase 3 - Busca e TF-IDF. A consulta digitada pelo usuário passa pelo mesmo pipeline de pré-processamento aplicado aos documentos. Para cada termo são calculados TF, DF e IDF, utilizando $IDF = \log(N/DF)$, e o TF-IDF é obtido pelo produto $TF \times IDF$. Em consultas com múltiplos termos, os valores são acumulados por documento. O resultado final é ordenado do maior para o menor valor, destacando o documento mais relevante.

3. Desafio bônus - Similaridade de Cosseno

Como funcionalidade adicional, foi implementada manualmente a Similaridade de Cosseno. A consulta e os documentos são representados por vetores TF-IDF construídos sobre o mesmo vocabulário. A similaridade é calculada pelo produto escalar entre os vetores dividido pelo produto de suas normas. O resultado é apresentado em um ranking separado, preservando o TF-IDF acumulado como mecanismo principal exigido pela atividade.

4. Testes realizados

Consulta	Resultado esperado	Finalidade do teste
irrigação	Documentos 1 e 5 relevantes	Normalização e busca por termo
irrigação soja	Doc 1 no topo do TF-IDF	Consulta com múltiplos termos
nitrogênio milho	Doc 3 em destaque	TF-IDF e similaridade de cosseno
cultivo orgânico	Doc 5 em destaque	Consulta com termos do mesmo documento
computador	Nenhum documento relevante	Tratamento de termo inexistente
IRRIGAÇÃO SOJA	Mesmo comportamento de 'irrigação soja'	Lowercase e remoção de acentos

5. Conclusão

O AgroSearch integra em uma única aplicação os conceitos estudados nas práticas de pré-processamento, índice invertido e TF-IDF. Os testes confirmaram o funcionamento da normalização, das opções de stopwords e stemming, da construção do índice e do ranqueamento das consultas. A Similaridade de Cosseno complementa a solução para consultas com múltiplos termos, permitindo comparar a direção dos vetores TF-IDF da consulta e dos documentos.

6. Divisão das atividades da equipe

Felipe: integração geral da aplicação em Streamlit, implementação e validação do pipeline de pré-processamento e organização da interface.

Arthur: implementação e validação do índice invertido e do cálculo e ranqueamento TF-IDF.

Julliane: implementação e validação da Similaridade de Cosseno, execução dos testes finais e apoio na elaboração e revisão do relatório.